


ESERCIZI



DEMO SESSION 2022/2023

5) - $l_0(x) = 0_0 + 0_1 x$ $\alpha = 0,01$ **APPLICAZIONE SGD**

$(0_0, 0_1) = (0, 0)$

$(x^*, y^*) = (5, 2)$

- $y_{pred} = l_0(x^*) = 0 + 0 \cdot 5 = 0$

$e = y_{pred} - y = 0 - 2 = -2$

$\frac{d}{d0_0} J(0) = \frac{d}{d0_0} \left[\frac{1}{2} (l_0(x^*) - y)^2 \right] = \frac{1}{2} \cdot 2 [l_0(x^*) - y] \cdot \frac{d}{d0_0} l_0(x^*) = (0 - 2) \cdot 1 = -2$

$\frac{d}{d0_1} J(0) = (0 - 2) \cdot x^* = -10$

$0_0 := 0_0 - \alpha \frac{d}{d0_0} J(0) = 0 - 0,01 \cdot (-2) = 0,02$

$0_1 := 0_1 - \alpha \frac{d}{d0_1} J(0) = 0 - 0,01 \cdot (-10) = 0,1$

6) ESERCIZIO PCA

- DATASET $X = \begin{pmatrix} 1 & 5 & 3 \\ 3 & 4 & 8 \\ 5 & 1 & 6 \end{pmatrix}$, MATRICE DELLA COVARIANZA $\Sigma = \begin{pmatrix} 4 & 1 & -4 \\ 1 & 7 & 3,5 \\ -4 & 3,5 & 7 \end{pmatrix}$

MATRICE AUTOVETTORI $U = \begin{pmatrix} -0,34517975 & 0,56157365 & 0,76503646 \\ -0,62304783 & -0,71757339 & 0,24421007 \\ -0,69652603 & 0,79704683 & 0,53702231 \end{pmatrix}$

MATRICE AUTOVALORI $S = \begin{pmatrix} 11,2312778 & 6,70771215 & 3,317172510 \cdot 10^{-16} \\ \lambda_1 & \lambda_2 & \lambda_3 \end{pmatrix}$

- **VARIANZA TOTALE** $= \lambda_1 + \lambda_2 + \lambda_3 \approx 18$

- CALCOLO RAPPORTI DI VARIANZA, MANTENENDO IL 60% DEL DATASET ORIGINALE

Dato scegliere un valore di K (i.e. n attributi il 60% del dataset originale):

Picco $K=1$ $\frac{\lambda_1}{\text{VAR. TOT.}} = 0,63 \geq 0,6$ } soglia $K=1$ perché mi basta per mantenere il 60% del dataset, nuovo ottenuto in cui $\leq 0,6$ o no
 Picco $K=2$ $\frac{\lambda_1 + \lambda_2}{\text{VAR. TOT.}} \approx 1$ } dovuto condizione $K=2$.

- SCELTA DEL NUM. FINITO DI COMPONENTI NECESSARIE

Ho scelto $K=1$ perché mi permette di mantenere il 60% del dataset, quindi le prime colonne

$U_{\text{REDUCE}} = \begin{pmatrix} -0,34517975 \\ -0,62304783 \\ -0,69652603 \end{pmatrix}$

* $\left[(v_1, v_2, v_3) \begin{pmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{pmatrix} \right] = (v_1 a_{11} + v_2 a_{21} + v_3 a_{31}, v_1 a_{12} + v_2 a_{22} + v_3 a_{32}, v_1 a_{13} + v_2 a_{23} + v_3 a_{33})$

- PROIEZIONE DEL DATASET ORIGINALE SU U_{REDUCE}

$Z = U_{\text{REDUCE}}^T \cdot X = (-0,34517975, -0,62304783, -0,69652603) \begin{pmatrix} 1 & 5 & 3 \\ 3 & 4 & 8 \\ 5 & 1 & 6 \end{pmatrix} = (-5,71, -10,34, -10,25)$

$$* [M_1, M_2, M_3] \cdot \begin{bmatrix} V_1 \\ V_2 \\ V_3 \end{bmatrix} = \begin{bmatrix} M_1 V_1 & M_1 V_2 & M_1 V_3 \\ M_2 V_1 & M_2 V_2 & M_2 V_3 \\ M_3 V_1 & M_3 V_2 & M_3 V_3 \end{bmatrix}$$

RICOSTRUZIONE DATI ORIGINALI

$$\tilde{X} = (I_{REDUCE} \cdot Z = \begin{pmatrix} -0,34517979 \\ -0,62306783 \\ -0,63652603 \end{pmatrix}) \begin{pmatrix} -5,74, -6,96, -10,25 \end{pmatrix} = \begin{pmatrix} 1,97 & 1,71 & 3,54 \\ 3,59 & 3,10 & 6,45 \\ 3,59 & 3,44 & 7,14 \end{pmatrix} \approx \begin{pmatrix} 2 & 2 & 4 \\ 4 & 3 & 6 \\ 4 & 3 & 7 \end{pmatrix}$$

DA CAPIRE SE HA SENSO

ESERCIZIO ROC (ATSOC)

1) Avendo dei dati come questi:

Esempio	Etichetta Reale	Probabilità Predetta
1	Positivo	0.95
2	Negativo	0.85
3	Positivo	0.80
4	Negativo	0.70
5	Positivo	0.65
6	Negativo	0.60
7	Positivo	0.40
8	Negativo	0.35
9	Positivo	0.20
10	Negativo	0.10

ricaviamo TPR (recall) e FPR (1 - specificity), impostando NOI la soglia:

$$TPR = \frac{TP}{TP+FN} \quad e \quad FPR = \frac{FP}{TN+FP}$$

Threshold = 0.45 => Il modello considera positivi tutti i valori ^{o uguale} maggiori di 0.45:

Ricavando da questo TP = 3 (E1, 3 e 5) FP = 3 (E2, 2, 4, 6) TN = 2 (E7, 8 e 10) FN = 2 (7 e 9)

$$\Rightarrow TPR = 0.6 \quad FPR = 0.6$$

$$\text{Threshold} = 0.85 \Rightarrow TP = 1 \quad FP = 1 \quad TN = 4 \quad FN = 6 \Rightarrow TPR = 0.25 \quad FPR = 0.35$$

ES. 1 STOCHASTIC

$$l_{\theta}(x) = \theta_0 + \theta_1 x \quad (x_1, y_1) = (5, 2) \quad (x_2, y_2) = (6, 3) \quad \alpha = 0,01$$

$$(\theta_0, \theta_1) = (0, 0)$$

$$l_{\theta}(x_1) = 0 \quad e_1 = 0 - 2 = -2$$

$$\frac{d}{d\theta_0} J(\theta) = \frac{1}{2} (l_{\theta}(x_1) - y_1) \quad \frac{d}{d\theta_0} l_{\theta}(x_1) = (-2) \cdot 1 = -2$$

$$\frac{d}{d\theta_0} J(\theta) = (-2) \cdot 3 = -10 \quad \theta_0 := \theta_0 - \alpha(-2) = -0,02 \quad \theta_1 := \theta_1 - \alpha(-10) = -0,1$$

$$l_{\theta}(x_2) = \theta_0 + \theta_1 x_2 = -0,02 + 0,01 \cdot 6 = 0,04 \quad e_2 = 0,04 - 3 = -2,96$$

$$\frac{d}{d\theta_0} J(\theta) = (-2,96) \cdot 1 = -2,96 \quad \frac{d}{d\theta_0} J(\theta) = (-2,96) \cdot 6 = -17,76$$

$$\theta_0 := \theta_0 - \alpha(-2,96) = -0,02 + 0,0296 = 9,6 \cdot 10^{-3} \quad \theta_1 := \theta_1 - \alpha(-17,76) = -0,1 + 0,1776 = 0,0776$$

BATCH CON STESSA FUNZIONE E DATASET

$$J(\theta) = \frac{1}{2} \sum_{i=1}^n (l_{\theta}(x_i) - y_i)^2$$

$$\hat{Q}_0 := Q_0 - 2 \cdot \frac{1}{n} \sum_{i=1}^{\lfloor n \cdot \hat{Q}_0 \rfloor} (h_0(i) - y_i) \cdot x_i$$

$$x_1 = -2 \quad x_2 = -3$$

$$\hat{Q}_0 := Q_0 - \frac{2}{n} (-2 - 3) = 0 - \frac{0.01}{2} \cdot -5 = 0.025$$

$$\hat{Q}_1 := \hat{Q}_0 - \frac{2}{n} (-2 \cdot 5 - 3 \cdot 6) = 0 - \frac{0.01}{2} \cdot (-21) = 0.105$$

ESERCIZIO ROC


$$0 = POS \quad 1 = NEG$$

Campione	Classe Reale	Probabilità Predetta
1	0	0.90
2	1	0.85
3	0	0.75
4	1	0.70
5	0	0.60
6	0	0.55
7	1	0.50
8	0	0.45
9	0	0.30
10	0	0.10

$$TNR = \frac{TN}{TN + FP}$$

$$PPV = \frac{TP}{TP + FN}$$

THRESHOLD	FPR	TNR	N°
0.90	0.10	0	1
0.85	0.10	0.33	2
0.75	0.20	0.33	3
0.70	0.20	0.66	4
0.60	0.40	0.66	5
0.55	0.50	0.66	6
0.50	0.50	1	7
0.45	0.70	1	8
0.30	0.80	1	9
0.10	1	1	10



ESERCIZIO QUANTILI ASTOC

2, 4, 5, 7, 8, 9, 10, 12, 14, 15, 30, 35

Q_1

Q_2

Q_3

sono già ordinati, ma lo sono ordinando. Prima trovare la mediana

$$Q_1 = \frac{5+7}{2} = 6 \quad Q_2 = \frac{9+10}{2} = 9.5 \quad Q_3 = \frac{14+15}{2} = 14.5$$

$$IQR = Q_3 - Q_1 = 8.5$$

$$Q_1 - 1.5 \cdot IQR = 6 - 12.75 = -6.75$$

$$Q_3 + 1.5 \cdot IQR = 14.5 + 12.75 = 27.25$$

Scarto 30 e 35.

$\Rightarrow 2, 6, \textcircled{5}, 7, 8, 9, 10, \textcircled{12}, 14, 15$
 $Q_1 \quad Q_2 \quad Q_3$

$$Q_2 = \frac{8+9}{2} = 8.5$$

$$(QR = Q_3 - Q_1 = 7$$

$$Q_1 - IQR \cdot 1.5 = -5.5$$

$$Q_3 + IQR \cdot 1.5 = 22.5 \quad \text{Im} \Rightarrow \text{No OUTLIER}$$

ESERCIZIO CLASSIFICATION TREE DEMO EXAM

Day	Outlook	Temperature	Humidity	Wind	PlayTennis
D1	Sunny	Hot	High	Weak	No
D2	Sunny	Hot	High	Strong	No
D3	Overcast	Hot	High	Weak	Yes
D4	Rain	Mild	High	Weak	Yes
D5	Rain	Cool	Normal	Weak	Yes
D6	Rain	Cool	Normal	Strong	No
D7	Overcast	Cool	Normal	Strong	Yes
D8	Sunny	Mild	High	Weak	No
D9	Sunny	Cool	Normal	Weak	Yes
D10	Rain	Mild	Normal	Weak	Yes
D11	Sunny	Mild	Normal	Strong	Yes
D12	Overcast	Mild	High	Strong	Yes
D13	Overcast	Hot	Normal	Weak	Yes
D14	Rain	Mild	High	Strong	No

Costruisce l'albero di classificazione da questo. Partiamo dalla formula generale dell'informazione gain per capire quale feature è la più impattiva.

$$\text{ENTROPIA: } H\left(\frac{T}{T+F}, \frac{F}{T+F}\right) = -\frac{T}{T+F} \log_2 \frac{T}{T+F} - \frac{F}{T+F} \log_2 \frac{F}{T+F}$$

(dove con T ed F si intendono le righe in cui viene triggerato il TRUE e FALSE rispettivamente (utilizzabile in più d'una riga totale, non in quella di un singolo feature, in quel caso si considerano solo le righe che hanno un determinato valore per quella feature)

$$\text{RESIDUO: } R(\text{feature}) = \sum_{i=1}^N \frac{T_i + F_i}{T+F} H\left(\frac{T_i}{T_i+F_i}, \frac{F_i}{T_i+F_i}\right)$$

dove con i si intende il numero di valori che assume una feature, T_i ed F_i : valori veri e falsi solo delle righe in cui la feature assume un determinato valore.

$$\text{GUADAGNO INFORMATIVO } IG(\text{feature}) = H\left(\frac{T}{T+F}, \frac{F}{T+F}\right) - R(\text{feature})$$

Per scegliere subito che il più efficace vedrà quale parte su due distinzione fra True o False, così si può capire l'attributo che 3 valori possibili, ed uno si associa con TRUE, ed anche con FALSE, i due altri possibili che non li associa a nessun.

$$H = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14} = 0.64 + 0.53 = 0.94$$

$$IG(\text{OUTLOOK}) = 0.94 - \left[\frac{5}{14} H\left(\frac{2}{5}, \frac{3}{5}\right) + \frac{4}{14} H(1, 0) + \frac{5}{14} H\left(\frac{3}{5}, \frac{2}{5}\right) \right] = 1 - \left[\frac{5}{14} \left(-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \right) + \frac{4}{14} (-1 \log_2 1) + \frac{5}{14} \left(-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \right) \right]$$

$$= 0.94 - \left[\frac{5}{14} (0.53 + 0.64) + \frac{5}{14} (0.64 + 0.53) \right] = 0.94 - 0.69 = 0.25$$

$$IG(\text{TEMP}) = 0.94 - \left[\frac{4}{14} \left(-\frac{2}{4} \log_2 \frac{2}{4} - \frac{2}{4} \log_2 \frac{2}{4} \right) + \frac{6}{14} \left(-\frac{4}{6} \log_2 \frac{4}{6} - \frac{2}{6} \log_2 \frac{2}{6} \right) + \frac{4}{14} \left(-\frac{3}{4} \log_2 \frac{3}{4} - \frac{1}{4} \log_2 \frac{1}{4} \right) \right]$$

$$= 0.94 - (0.29 + 0.39 + 0.21) = 0.94 - 0.91 = 0.03$$

PROVA DI ALBERO A SENTIMENTO

1) 1/3 - 4 0/3 0/3 0/2

2) a. 2/3 - 3 2/2 0/2

b. 0/2 0/2 0/2



1.

1. SPIEGARE HOLD-OUT, K-FOLD CROSS VALIDATION, RANDOM SAMPLING.
2. VANTAGGI E SVANTAGGI DELLA REGOLARIZZAZIONE CON $C1$ E $C2$.
3. SPIEGARE L'USO DEI QUANTILI E ESERCIZIO SEMPLICE.
4. ESERCIZIO DI AGGIORNAMENTO DEI THETA NEL CASO FULL BATCH E STOCHASTIC.
5. ESERCIZIO SUL ROC.
6. DATI 3 GRAFICI DISEGNARE E SPIEGARE LE LEARNING CURVE.
7. SPIEGARE COSA SONO LE LEARNING CURVE E I LORO COLLEGAMENTI CON BIAS E VARIANZA.
8. PSEUDO CODE BATCH, STOCHASTIC E MINIBATCH.
9. SPIEGARE SUPERVISED E UNSUPERVISED CON ESEMPLI.
10. MECCANISMO ONE VS ALL E ALL VS ALL.

BATCH GRADIENT DESCENT

$$\theta_j := \theta_j - \alpha \sum_{n=1}^m (\ell(x^{(n)}) - y^{(n)}) x_j^{(n)}$$

PSEUDO CODICE

```

theta = rand
while (not convergence) {
  for (j from 1 to n) {
    update = 0
    for (i from 1 to m) {
      update = update + (l(x[i]) - y[i]) * x[i]
    }
    theta_new[j] = theta[j] - alpha * update / m
  }
  theta = theta_new
}

```

STOCHASTIC GRADIENT DESCENT

$$\theta_j := \theta_j - \alpha (\ell(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

PSEUDO CODE

```

theta = rand()
while (not converge) {
    for (i from 1 to m) {
        for (j from 1 to n) {
            theta_new[j] = theta[j] - 2 * (h(x[i]) - y[i]) * 1/n * x[i]
        }
    }
    theta = theta_new
}

```

MINI-BATCH GRADIENT DESCENT

PSEUDO CODE

```

k = 50
while (not converge) {
    while (i < m) {
        for (j from 1 to n) {
            update = 0
            for (z from i to i+k) {
                update = update + (h(x[z]) - y[z]) * x[z]
            }
            theta[j] = theta[j] - 2 * update/k
        }
        i = i + k;
    }
}

```

NORMAL EQUATIONS DERIVATIVES

$$\text{TESI: } \nabla J(\theta) = X^T X \theta - X^T y = 0 \Rightarrow \hat{\theta} = (X^T X)^{-1} + X^T y$$

$$\text{Dih: } J(\theta) = \frac{1}{2n} \sum_{i=1}^n (h(x^{(i)}) - y^{(i)})^2 \quad \text{with: } J(\theta) = \frac{1}{2} (X\theta - y)^T (X\theta - y)$$

$$(X\theta - y) = \begin{pmatrix} h(x^{(1)}) - y^{(1)} \\ \vdots \\ h(x^{(n)}) - y^{(n)} \end{pmatrix} \Rightarrow \text{approx } h(X\theta - y)^T (X\theta - y) = \sum_{i=1}^n (h(x^{(i)}) - y^{(i)})^2$$

$$\text{ocal: } \frac{d}{d\theta_k} J(\theta) = \frac{1}{n} \sum_{i=1}^n (h(x^{(i)}) - y^{(i)}) x_k^{(i)} \quad \text{with: } \nabla J(\theta) = (h(x^{(1)}) - y^{(1)}), \dots, (h(x^{(n)}) - y^{(n)}) \begin{pmatrix} x_k^{(1)} \\ \vdots \\ x_k^{(n)} \end{pmatrix}$$

$$\Rightarrow \nabla J(\theta) = \begin{pmatrix} \sum_{i=1}^n l(x^{(i)}) - y^{(i)} \\ \sum_{i=1}^n (l(x^{(i)}) - y^{(i)}) x_1^{(i)} \\ \vdots \\ \sum_{i=1}^n (l(x^{(i)}) - y^{(i)}) x_n^{(i)} \end{pmatrix} \Rightarrow x^T x \theta - x^T y = 0 \Rightarrow \hat{\theta} = (x^T x)^{-1} + x^T y$$

APPROCCIO PROBABILISTICO DELLA REGRESSIONE LINEARE

TES1: $y^{(i)} = l(x^{(i)}) + e^{(i)}$, $\max_{\theta} L(\theta) = \min_{\theta} J(\theta)$

Def: $p(e^{(i)}) = N(0, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(e^{(i)})^2}{2\sigma^2}}$, dato $e^{(i)} = y^{(i)} - l(x^{(i)})$

$$\Rightarrow p(y^{(i)} | x^{(i)}; \theta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - l(x^{(i)}))^2}{2\sigma^2}}$$

$$L(\theta) = L(\theta; x; y) = p(y | x; \theta) = \prod_{i=1}^n p(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - l(x^{(i)}))^2}{2\sigma^2}}$$

$$\ln L(\theta) = \ell(\theta)$$

$$\begin{aligned} \hat{\theta} &= \arg \max_{\theta} L(\theta) = \arg \max_{\theta} \ln L(\theta) = \arg \max_{\theta} \ell(\theta) = \arg \max_{\theta} \ln \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - l(x^{(i)}))^2}{2\sigma^2}} = \\ &= \max_{\theta} \sum_{i=1}^n \ln \left[\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(y^{(i)} - l(x^{(i)}))^2}{2\sigma^2}} \right] = \max_{\theta} \sum_{i=1}^n \ln \frac{1}{\sqrt{2\pi}\sigma} - \dots \end{aligned}$$

AGGIORNAMENTO PESI BACKPROPAGATION

calcolo parziale stato di output: $\delta_k^{(l)} = \frac{dJ(\theta)}{da_k^{(l)}} = (a_k^{(l)} - y) g'(z_k^{(l)})$

calcolo il grad per n neuroni in uno stato precedente con somme degli stati successivi:

$$\delta_j^{(l)} = \sum_k (\delta_k^{(l)} \delta_{kj}^{(l+1)}) g'_j(z_j^{(l)})$$

Da questo si ottiene con l'uso di cinque neuroni i pesi del prossimo a ottenere.

$$\frac{dJ(\theta)}{d\theta_{kj}^{(l)}} = \delta_j^{(l+1)} a_j^{(l)}$$

$$\delta_k^{(l)} = \frac{dJ(\theta)}{da_k^{(l)}} = (a_k^{(l)} - y) g'(z_k^{(l)})$$

$$\delta_j^{(l)} = \sum_k (\delta_k^{(l)} \delta_{kj}^{(l+1)}) g'_j(z_j^{(l)})$$

$$\frac{dJ(\theta)}{d\theta_{kj}^{(l)}} = \delta_k^{(l+1)} a_j^{(l)}$$

$$\theta_{kj}^{(l)} := \theta_{kj}^{(l)} - \alpha \frac{dJ(\theta)}{d\theta_{kj}^{(l)}}$$